최종 보고서

Oct 24, 2026 · @CV 실습 04

프로젝트 개요

항목	내용
프로젝트	오픈스페이스 알박기 감지 시스템 (한양대 ERICA 융합교육관 스터디룸 14 개)
기간	2026 년 10 월 13 일 ~ 10 월 23 일 기획 10/13 · 1 차 회의 10/15 · 2 차 회의 10/21 · 최종 발표 10/22 · 발표 후 보강 10/23
팀	알박기 척결
팀원과 역할	황예성: 총괄·기획, 발표 자료 제작과 발표, 프로젝트 전반 검수 이창민: 라즈베리파이 카메라 송출과 실측 박서준: 서버 판정 프로그램, YOLO 검증·실험
최종 결과물	발표 자료, 판정 모델(YOLO26s v2), 통합 실행 프로그램, MVP 관제 대시보드, GitHub 10_Project

문제해결과정

프로젝트는 "30 분 자리 비움 규칙은 있지만, 지켜졌는지 확인할 수 없다"는 문제에서 출발했다. 1 차 회의(10/15)에서는 YOLO11s 로 사람과 테이블을 찾고, 테이블 박스를 가로·세로 30% 넓힌 감지 영역 안에 사람이 있는지로 재석을 판단하기로 했다. 엎드린 사람은 못 잡을 것이라는 우려가 나와 회의 중에 사진 6 장으로 바로 확인했고, 모델 6 종이 모두 6 장을 잡아 사전학습 모델로 충분하다고 봤다. 이후 실제로 만들고 시험하면서 아래 문제를 차례로 만났다.

검증 방법. 룸 14 개를 실제로 다 찍을 수 없어서, 스터디룸 14 개 디지털 트윈에 가상 학생을 넣고 룸별 천장 카메라 화면을 YOLO 서버로 판정했다. 앉은 사람은 98.2%, 룸 판정은 92.0%(112 장)로 좋아 보였지만, 가장 중요한 엎드린 사람이 48.9%로 실제 사진(6/6)과 정반대였다. GPU 없이 렌더링하면 4 명이 있는 룸을 0 명으로 판정하기도 했다. 점수가 모델 성능이 아니라 그래픽의

한계를 재고 있었고, 가상 화면을 실제에 맞추는 시간이 실제 룸을 한 번 찍는 것보다 컸다. 그래서 하루 만에 시뮬레이션을 멈추고, 실제 룸 천장에 카메라를 달아 22 분을 찍어 검증했다.

테이블 검출. 실제 영상에서는 1 차 회의의 전제가 무너졌다. 사전학습 모델은 책상을 식탁(dining table)으로만 배워, 천장에서 내려다본 우리 테이블을 거의 찾지 못했다(YOLO26s 2%). 테이블을 못 찾으면 감지 영역을 만들 수 없다. 모델을 키우면 해결될지 보려고 사전학습 모델 16 종을 같은 조건으로 비교했지만, 테이블과 엎드린 사람을 둘 다 잡는 모델은 없었다. 테이블을 잡는 YOLO11l 은 엎드린 사람이 31%, 엎드린 사람을 잡는 YOLOv10s 는 테이블이 8%였다. 모델 크기가 아니라 데이터의 문제라고 보고 파인튜닝으로 방향을 바꿨다.

파인튜닝. 우리 룸에서 만든 데이터 727 장(학습 637 + 검증 90)으로 학습했는데, 1 차 학습은 테이블 위주 데이터라 테이블은 100%가 됐지만 사람을 잊어버렸다(사람 100%→68%, 가방 89%→14%). 사람 데이터를 같이 넣고 학습률을 낮춘 v2 에서 둘 다 해결했다(테이블 2%→100%, 엎드린 사람 92.9%→100%). 공정하게 평가하려고 천장 영상의 뒤 20%와 웹캠 영상은 학습에 넣지 않고 시험에만 썼다.

모델	파라미터	테이블	엎드린 사람	GPU 1 장
YOLO26n (전)	2.6M	3%	65.5%	17.9ms
YOLO26s (전)	10.0M	2%	92.9%	21.0ms
YOLO11s v2	9.5M	100%	98.8%	17.7ms
YOLO26s v2 (최종)	10.0M	100%	100%	18.1ms
YOLO26m v2	21.9M	100%	100%	21.6ms

학습에 안 쓴 영상 기준, GPU 는 팀 노트북 RTX 5060·입력 960·30 회 중앙값.

엎드린 사람 데이터. 엎드린 사람 사진이 부족해, 생성형 데이터로 채울 수 있는지 시험했다. 직접 찍은 빈 룸 사진의 의자 자리 4 곳에 Stable Diffusion 인페인팅(사진 일부만 새로 그리는 기법)으로 엎드린 사람을 그려 넣고, CLIP 으로 먼저 거른 뒤 눈으로 확인했다. 지시문과 옷차림을 바꿔 세 번에 걸쳐 80 장을 만들었고, 그중 엎드린 장면은 40 장이다. 결과적으로 학습에는 쓰지 않았다. YOLO26s 가 엎드린 장면 40 장을 모두 잡아 새로 배울 것이 없었고, 진짜 약점이던 천장 각도의 테이블은 합성 사진으로 풀 수 없었으며, 1 장 만드는 데 약 70 초가 걸렸다. 대신 약점을 찾는 데는 쓸모가 있었다. 후드를 쓰고 엎드린 사람은 더 큰 YOLO26l 도 신뢰도 0.14 로 놓쳤다. 그래서 시범 수집 때 후드 쓰고 엎드린 장면을 먼저 모으기로 했다.

감지 영역. 테이블을 잡게 된 뒤에는 사각형 박스가 통로까지 덮어, 지나가는 사람도 재석으로 세는 문제가 남았다. 그래서 SAM 으로 테이블 테두리만 따고, 짧은 변의 15%만큼 부풀려 감지 영역으로 썼다. 테이블 끝자리 사람까지 잡으려고 영역을 더 넓히자 유리벽 너머 옆방 사람까지 잡혔다. 그래서 영역은 +15%로 두고 사람 박스의 겹침 기준을 낮췄다. 25%와 15%에서는 마지막 사람이 나가는 순간 사람이 있는데도 룸을 비었다고 본 순간이 있었고, 10%에서는 없어서 최종 기준을 10%로 정했다.

판정 위치와 카메라. 1 차 회의에서는 룸마다 라즈베리파이를 두고 그 안에서 직접 추론하는 안을 검토했다. 라즈베리파이 4B 에서 같은 YOLO26s v2 를 영상 659 장으로 실측해 보니 정확도는 같았지만, 1 장에 2,832ms(초당 0.35 장)가 걸려 1 초마다 판정할 수 없었다. GPU 서버(18.1ms)보다 약 156 배 느리다. 또 최고 81.3°C 까지 올라 하루 종일 돌리기 어렵고, 14 대를 따로 관리해야 하며 초기 비용도 약 240 만 원으로 PC 한 대보다 컸다. 클라우드 GPU 는 빠르지만 월 약 60 만 원이 들고 영상이 학교 밖으로 나간다. 그래서 GPU 가 있는 교내 PC 1 대에서 14 개 룸을 모두 판정하기로 했다. 카메라도 기존 CCTV 는 한 화면에 여러 룸이 겹치고 스터디룸 안에는 없었으며, 앱 전용 홈캠은 RTSP 로 영상을 받을 수 없고 영상이 제조사 클라우드를 거쳤다. 그래서 RTSP 로 교내망에서 직접 받을 수 있는 Tapo C210 을 골랐다.

타깃과 비용. 교수님 피드백으로 "누구에게 파는가"와 "비용이 정말 최소인가"를 다시 정리했다. 고객은 학교 운영 담당, 사용자는 학생인 B2B 로 정하고, 모든 선택을 ① 정확도·속도 ② 비용 ③ 운영·유지보수 ④ 개인정보로 판단했다. 처음 비용에는 PoE 스위치, 업체 시공, 현황판 모니터가 들어 있었는데, 와이파이 카메라로 바꿔 PoE 와 시공을 빼고 현황판은 고도화 단계로 미뤘다. "오픈소스도 공짜가 아니다"라는 지적에 따라 점검·고장 수리·재학습 인건비를 룸당 월 1.5 만 원 구독에 넣었고, 초기 207 만 원, 연 252 만 원(학생지원비의 0.02%)으로 정리했다. 서버 사양은 노트북 실측(1 장 18.1ms)을 GPU 연산 성능 비율로 환산해 최소 GTX 1060 급으로 정했다.

빈 책상. 판정 규칙에도 빈틈이 있었다. 사람이 없는 시간만 재다 보니, 짐까지 챙겨 나간 빈 책상도 노랑으로 30 분을 기다렸다. 노랑은 짐 주인이 돌아올 수 있으니 기다린다는 뜻인데, 짐이 없으면 기다릴 이유가 없다. 그래서 감지 영역 안의 짐(가방·노트북·책 등 11 종)도 함께 보고, 사람도 짐도 10 초 연속 없으면 바로 초록으로 바꾸게 했다. 파인튜닝 모델은 가방을 거의 못 잡아서, 가방을 놓쳐 짐 있는 책상이 빈 책상으로 보이지 않도록 가방류의 신뢰도 기준은 0.10 으로 낮췄다.

설명하기 어려운 결과. 판정 방식과 도입 효과는 말로 설명하기 어려웠다. 그래서 실제 룸 영상 22 분을 더미 데이터로 삼아 14 개 룸을 가상으로 운영하는 관리자 대시보드(MVP)를 만들었다.

저녁 식사 시간 룸 활성화율이 도입 전 22%에서 도입 후 50%로 바뀌는 것을 한 화면에서 보여 줄 수 있게 됐다.

발표 후 보강. 최종 발표(10/22) 당일 받은 피드백을 반영해 프로젝트를 보강했다. 발표 시점에는 판정 코드, 모델, 대시보드가 따로 있어, 카메라 영상을 받아 판정하고 신호등까지 보내는 프로그램이 없었고 룸 14 개 동시 처리도 시험하지 못한 상태였다. 그래서 카메라 여러 대 → 판정 → 신호등·기록·현황 화면을 한 번에 돌리는 통합 실행 프로그램을 만들고, 영상 하나를 룸 14 개처럼 복제해 1 초마다 판정했다. 한 바퀴(14 개 룸) 처리 시간은 중앙값 453ms 로, 1 초 간격 판정이 가능했다. 현황 화면이 카메라 사진을 2 초마다 한 장씩 불러와 끊겨 보이는 문제는, 판정은 1 초마다 그대로 하고 화면만 실시간 영상으로 보내 해결했다. 박스가 최대 1 초 늦게 따라오므로, 모자이크는 사람 박스보다 25% 넓게 씌웠다.

카메라 각도와 성능 측정. 보강 중 웹캠으로 성능을 확인하다가 새 문제를 찾았다. 파인튜닝 모델이 정면 웹캠 앞 사람을 14 장 중 2 장만 찾았다(기본 YOLO26s 는 14 장 모두). 천장에서 내려다본 사진으로만 학습해, 학습한 각도에는 강해진 대신 다른 각도에는 약해진 것이다. 실제 설치는 천장 카메라라 운영에는 파인튜닝 모델을 그대로 쓰지만, 카메라 각도가 바뀌면 그 각도의 데이터로 다시 학습해야 한다는 뜻이기도 하다. 또 웹캠 확인 화면의 처리량(1 초에 룸 14~17 개)이 발표의 초당 55 장보다 낮게 나왔는데, 판정과 화면 그리기를 한 프로그램에서 같이 하고 노트북이 배터리 전원이었기 때문이었다. 화면 없이 판정만 하면 1 장 29.4ms(1 초에 약 34 개)로, 가장 불리한 조건에서도 룸 14 개를 1 초 안에 판정할 수 있었다.

남은 문제. 현장 데이터가 룸 1 곳(영상 22 분)뿐이고, 실제 카메라 14 대(RTSP)와 GTX 1060 급 장비로 한 시험은 아직 하지 않았다. 그래서 학교 협조를 받아 7 일 동안 운영과 같은 천장 각도로 현장 데이터를 모으되 후드 쓰고 엎드린 장면처럼 약한 장면을 먼저 모으고, 재학습·시험에 합격하면 적용하기로 했다.

진행 사항

프로젝트 진행 흐름

프로젝트는 기획(10/13)부터 발표 후 보강(10/23)까지 아래 순서로 진행했다. 팀원마다 맡은 실험을 동시에 진행하고, 회의에서 결과를 모아 다음 방향을 정했다. 각자 한 일의 자세한 내용은 팀원별 개인 자료에 있다.

날짜	단계	한 일	담당

날짜	단계	한 일	담당
10/13	기획	주제를 오픈스페이스 알박기로 좁히고 스터디룸 14 개를 현장 조사했다. 핵심 문제를 "30 분 규칙은 있는데 지켜졌는지 확인할 수 없다"로 정하고 6 Pager 기획서(문제분석지·PR·FAQ 19 문항)를 썼다.	황예성
10/15	1 차 회의	역할을 나누고 판정 방식(YOLO11s, 테이블 박스 +30% 감지 영역, 10 초 가림 보정, 3 색 규칙)과 판정 코드(MVP)를 정했다. "엎드린 사람은 못 잡는다"는 우려는 회의 중 사진 6 장으로 확인했다(6 종 모두 6/6).	전원 (판정 코드·검증: 황예성)
10/15~17	카메라 송출	라즈베리파이 카메라 영상 송출(HTTP/MJPEG), PC 에서 받은 영상으로 YOLO 추론 테스트, 수신 스트림 녹화 기능을 만들었다.	이창민
10/15~17	3D 검증과 중단	스터디룸 14 개 3D 디지털 트윈으로 시험했지만 엎드린 사람이 48.9%(실제 6/6)로 나와 중단하고, 실제 룸 천장 카메라 영상(22 분) 검증으로 바꿨다.	황예성
10/18	모델·데이터	사전학습 YOLO 16 종을 비교했지만 테이블과 엎드린 사람을 둘 다 잡는 모델이 없었다. 학습 데이터 727 장을 만들고(테이블 라벨 181 장 검수), 1 차 학습 실패 뒤 v2 로 파인튜닝했다(테이블 2%→100%).	황예성
10/18~21	판정 프로그램·검증	판정 프로그램(server.py)과 다각형 감지 영역을 만들고, 사전학습 15 종 비교, 정답 659 장 프레임 검증(v2 학습 외 구간 131/132), 생성형 데이터 80 장 실험, 공개 데이터셋 10 종 조사, 실시간 수신 화면을 진행했다.	박서준

날짜	단계	한 일	담당
10/20~21	비용·사양·감지 범위	B2B 비용(초기 207 만 원, 구독 연 252 만 원 = 학생지원비의 0.02%), 서버 최소 사양(GTX 1060 급), SAM 감지 범위(+15%, 겹침 기준), 시스템 컨텍스트 다이어그램, MVP 관제 대시보드를 만들었다.	황예성
10/20~21	라즈베리파이 실측	송출을 H.264 RTSP 로 바꾸고, 라즈베리파이 4B 에서 YOLO26s v2 를 직접 돌리는 벤치마크를 했다(1 장 2,831.8ms, 최고 81.3°C).	이창민
10/21	2 차 회의	실험 결과를 모아 판정은 교내 PC 1 대, 모델은 YOLO26s v2, 감지 범위는 SAM +15%로 정하고 라즈베리파이와 클라우드 GPU 는 제외했다. 발표 자료를 팀원 피드백으로 고쳤다.	전원
10/22	최종 발표	리허설 녹음으로 발표문을 다듬고 빈 책상 바로 초록 규칙을 넣었다. 발표 자료 수정본과 예상 질문을 정리하고 최종 발표를 했다.	황예성(발표) 박서준(수정본·예상 질문)
10/23	발표 후 보강	발표 당일 받은 피드백을 반영해, 카메라 영상 → 판정 → 신호등·현황 화면을 한 번에 돌리는 통합 실행 프로그램(룸 14 개 한 바퀴 453ms)과 웹캠 성능 확인 창을 만들고 저장소와 보고서를 정리했다.	황예성

주요 논의와 결론

주제	내용	결론
추론 위치	라즈베리파이 내부 추론 vs 서버 판정	라즈베리파이는 1 초 간격 불가·과열로 제외, 교내 PC 1 대
모델 크기	nano 는 엎드린 사람 65.5%, m·l 은 정확도 같고 느림	YOLO26s (GPU 에서는 n 과 속도 차이 거의 없음)
학습 여부	1 차에서는 사전학습으로 충분하다고	파인튜닝하기로 변경

주제	내용	결론
	봤으나 테이블을 못 잡음	
감지 영역	사각형 박스는 통로까지 덮고, 더 넓히면 유리벽 너머 옆방이 잡힘	SAM 테두리 +15%, 겹침 10%
타깃	교수님 피드백 "타깃을 정하라"	B2B: 고객은 학교, 사용자는 학생. 판단 기준 4 가지(정확도·속도, 비용, 운영, 개인정보)
비용	교수님 피드백 "비용이 최소인지, 오픈소스도 공짜가 아니다"	초기 207 만 원, 구독 연 252 만 원(학생지원비의 0.02%)
합성 데이터	기존 모델이 이미 잡는 장면이라 학습에 새로 줄 정보가 없음	학습 제외, 약점 찾기에 활용

시도했다가 제외한 것

직접 해 보고 숫자로 판단해 버린 안이다. 걸린 기준은 학교 입장의 판단 기준 번호다(① 정확도·속도 ② 비용 ③ 운영·유지보수 ④ 개인정보).

시도	결과	걸린 기준	대신 고른 것
기존 CCTV 활용	한 화면에 여러 룸이 겹치고, 스터디룸 안에는 CCTV 가 없음	①	룸마다 카메라 1 대
가정용 홈캠(앱 전용)	RTSP 로 영상을 받을 수 없고 영상이 제조사 클라우드를 거침	④	RTSP 지원 Tapo C210
3D 디지털 트윈 검증	엎드린 사람 48.9%(실제 사진은 6/6). GPU 없이 렌더링하면 4 명을 0 명으로 판정	①	실제 사진·실제 룸 영상으로 검증
룸별 라즈베리파이 추론	1 장 2,832ms(초당 0.35 장), 최고 81.3°C, 14 대 초기 약 240 만 원	①②③	교내 PC 1 대(GPU 1 장 18.1ms)
클라우드 GPU	월 약 60 만 원, 영상이 학교 밖으로 나감	②④	교내 PC 1 대

시도	결과	걸린 기준	대신 고른 것
사전학습 모델 그대로 사용	16 종 중 테이블과 엎드린 사람을 둘 다 잡는 모델 없음(기존 YOLO11s 엎드림 6%)	①	우리 영상으로 파인튜닝
1 차 파인튜닝(테이블 위주)	테이블은 100%지만 사람을 잊음(사람 100%→68%, 가방 89%→14%)	①	사람 데이터를 넣고 학습률을 낮춘 v2
Stable Diffusion 합성 데이터로 학습	합성 80 장(엎드린 장면 40 장)을 기존 모델이 이미 잡아 새로 줄 정보가 없었고, 진짜 약점(천장 각도의 테이블)은 합성 사진에 없음	①②	현장 데이터. 합성 사진은 약점 찾기에 활용
더 큰 모델 YOLO26m·l	정확도는 같고 CPU 에서 2.7~3.4 배 느림	①	YOLO26s
더 작은 모델 YOLO26n	엎드린 사람 65.5%, GPU 에서는 s 와 속도 차이 없음	①	YOLO26s
YOLO 테이블 박스를 30% 넓힌 감지 영역	사각형이라 비스듬한 테이블 옆 통로까지 덮어 지나가는 사람도 재석으로 셈	①	SAM 테이블 테두리 +15%
감지 영역을 더 넓히기	유리벽 너머 옆방 사람까지 잡힘	①	겹침 기준 25% → 10%
PoE 스위치·업체 시공·현황판 모니터	와이파이 홈캠이라 불필요, 현황판은 고도화 단계	②	교내 와이파이 연결, 전기 공사만(총 30 만 원)

팀 결정 사항 전체

분야	결정	이유
방향	B2B: 고객은 학교 운영 담당, 사용자는 학생	교수님 피드백 "타깃을

분야	결정	이유
		정하라". 학생은 앱 설치·입력 없이 색만 봄
판단 기준	① 정확도·속도 ② 비용 ③ 운영·유지보수 ④ 개인정보	모든 선택을 학교 입장에서 비교하기 위해
카메라	룸마다 Tapo C210 1 대(대당 45,900 원), RTSP 로 교내망 직접 수신, 교내 와이파이 연결, 천장에 고정해 책상이 잘 보이도록 설치	룸 하나 = 화면 하나, 업체 시공 불필요
신호등	가로형 3 색 신호등을 문이나 문 위에 부착. 빨강 사용중, 노랑 30 분 미만, 초록 30 분 이상 또는 빈 책상(사람도 짐도 없음)	복도에서 바로 보이게. 초록이면 짐을 룸 앞 바구니로 옮기고 사용
판정 서버	교내 PC 1 대: 최소 GTX 1060 급, 권장 GTX 1070 급 + 6 코어 라이젠 5 5600 급 + 램 16GB(약 50 만 원)	룸 14 개 × 1 초 1 장 = 1 장 71ms 안. CPU 는 카메라 14 대 영상 디코딩 과부하 방지
모델	YOLO26s v2(파인튜닝), 입력 960, 엎드린 사람 기준값 0.35	테이블·사람·엎드린 사람 모두 100%, NMS-free 로 후처리 없음
데이터	727 장(학습 637 + 검증 90). 천장 영상 앞 80%는 학습, 뒤 20%와 웹캠 영상은 시험에만 사용	학습에 안 쓴 영상으로 공정하게 평가
평가 지표	사람·엎드린 사람 검출률, 테이블 IoU 0.5 이상 비율, 1 장당 처리 시간, 파라미터 수	사람을 놓치면 초록불이 켜져 짐을 치우게 됨. 속도·크기는 서버 비용과 직결
감지 영역	SAM 테이블 테두리를 짧은 변의 15%만큼 부풀림, 사람 박스가 10% 이상 겹치면 재석.	통로·옆방 오탐 방지

분야	결정	이유
	설치 때와 테이블이 움직였을 때만 다시 딴	
판정 보정	사람이 10 초 넘게 안 보여야 부재, 2 초 연속 보여야 재석	가려짐으로 인한 오판과 순간 오검출 방지
개인정보	얼굴 식별 없음, 영상 저장 없음, 교내망 밖 전송 없음, 색이 바뀐 순간 스냅샷만 모자이크해 1 일 보관, 기록은 시각·룸·색만, 공개 자료도 모자이크	학생을 찍는 시스템이라 처음부터 설계에 포함
비용	초기 207 만 원(카메라 64 만, PC 50 만, 신호등 49 만, 전기 공사 30 만, 부자재 14 만). 구독 룸당 월 1.5 만 원(점검·고장 수리·재학습 인건비 포함, 출장비 제외). 전기세는 학교 부담	오픈소스도 공짜가 아님. 룸 단위라 일부 룸부터 도입 가능. 연 252 만 원 = 학생지원비의 0.02%
시범 운영	학교 협조 → 7 일 현장 수집(운영과 같은 천장 각도, 후드 쓰고 엎드린 장면 먼저) → 재학습·테스트 → 합격 시 적용	현장 데이터가 룸 1 곳뿐이라 실증으로 채움
불합격·중단 기준	불합격: 관찰 300 회 중 잘못된 초록 1 건 이상 또는 빈 룸 놓침 2% 초과. 중단: 개인정보 검토 불통과 또는 분실·다툼 문의 주 3 건 이상	잘못 켜진 초록 한 번이 곧 민원
고도화	1 층 현황판, 짐 검출	MVP 범위 밖, 초기 비용 최소화

추후 계획

시범 운영 계획

최종 발표 이후에는 실제 룸에서 시범 운영을 거쳐 적용하는 것을 목표로 한다.

- 학교 협조: 시설팀에 카메라 설치 가능 여부를 묻고, 운영 승인과 개인정보 검토를 받는다.

- 7 일 현장 수집: 운영과 같은 천장 각도로 14 개 룸을 찍되, 후드 쓰고 엎드린 장면처럼 약한 장면을 먼저 모은다.
- 재학습과 시험: 현장 데이터로 다시 학습하고, 14 개 룸을 하루 3 번씩 7 일(약 300 회) 직접 관찰해 판정과 비교한다. 합격하면 14 개 룸에 적용한다.
- 장비 실측: 실제 카메라 14 대(RTSP)와 GTX 1060 급 PC 로 통합 실행 프로그램을 돌려, 1 초 간격 판정을 다시 확인한다.

기타

- 시범 운영 불합격 기준을 미리 정했다: 14 개 룸을 하루 3 번씩 7 일, 약 300 회 직접 관찰해 판정과 비교하고, 주인이 있는데 초록이 켜진 경우 1 건 이상 또는 빈 룸을 놓친 경우 2%(6 건) 초과면 재학습한다.
- 중단 기준: 개인정보 검토 불통과 또는 짐 분실·다툼 문의 주 3 건 이상이면 장비를 철거하고 기록을 모두 삭제한다.
- 남은 문제: 현장 데이터가 룸 1 곳(영상 22 분)뿐이고, 실제 카메라 14 대(RTSP)와 GTX 1060 급 실측은 아직 못 했다. 30 분 직전에 잠깐 들르면 타이머가 초기화된다.
- 고도화: 1 층 현황판(층을 돌지 않고 빈 룸 확인), 짐 검출

박서준 개인 연구 보고: 서버 판정 시스템 설계와 YOLO 검증

담당: 서버 판정 프로그램, YOLO 모델 비교·검증, 생성형 데이터 실험. 코드와 프레임별 결과는 GitHub 10_Project 폴더(https://github.com/gosu1/ERICA_X_MODULABS_CV/tree/main/10_Project)에 있고, 이 보고서의 모든 수치는 그 기록에서 가져왔다.

요약

사전학습 YOLO 15 종(v8·11·26 계열의 n~x)을 우리 데이터 세 종류로 비교해, 파라미터 대비 성능이 가장 좋은 YOLO26s 를 골랐다. YOLO26s(9.5M)는 파라미터가 6 배인 YOLO11x(56.9M)와 합성 엎드린 장면 검출 수, 1 차 영상 사람 최저 신뢰도가 같았고, 연산량은 9 분의 1 이었다. 판정 프로그램(server.py)은 2 프레임 연속 확인과 끊긴 시간 제외 규칙을 넣어 만들었다. 정답을 표기한 1 차 영상 659 장에서 사전학습 YOLO26s 는 656 장(99.5%)이 맞았고, 팀의 파인튜닝 모델 v2 는 학습에 쓰지 않은 구간 132 장 중 131 장이 맞았다. v2 가 틀린 1 장은 규칙이 의도한 2 초 지연이었다. Stable Diffusion 인페인팅으로 만든 합성 사진 80 장은 학습 데이터로는 효용이

낮았지만, 모델이 후드를 쓰고 엎드린 사람에게 약하다는 점을 찾아 시범 수집의 우선순위를 정하는 근거가 됐다.

1. 연구 질문

서버 판정을 맡으면서 아래 여섯 가지 질문을 세우고, 각각 우리 데이터로 답했다.

표 1. 연구 질문, 방법, 결론

번호	연구 질문	방법	결론
RQ1	파라미터 대비 성능이 가장 좋은 사전학습 YOLO 는 무엇인가	15 종 × 우리 데이터 3 종, COCO 공식 지표	YOLO26s
RQ2	사전학습 모델로 테이블을 잡아 감지 영역을 만들 수 있는가	15 종의 COCO dining table 신뢰도	불가. 다각형 영역으로 대체
RQ3	판정 규칙이 실제 영상에서 의도대로 동작하는가	정답 659 장과 프레임 단위 비교, 끊김·강제 종료 시험	26s 99.5%, v2 학습 외 구간 131/132
RQ4	생성형 데이터로 엎드린 사람 데이터를 채울 수 있는가	SD 인페인팅 80 장, CLIP 필터, 15 종 평가	학습 효용 낮음, 약점 탐색에 유효
RQ5	우리 환경과 비슷한 공개 데이터가 있는가	10 종 조사(공식 페이지, 논문, 라이선스)	스터디룸 각도의 엎드림 데이터 없음
RQ6	카메라 영상을 지연 없이 실시간 판정할 수 있는가	최신 프레임만 유지하는 수신 구조	초당 17.8 장 표시

2. 실험 환경과 데이터

표 2. 실험 환경

항목	내용
장치	M2 맥북 16GB, MPS(애플 GPU)
소프트웨어	Python 3.12, Ultralytics, OpenCV, diffusers 0.41(합성 실험)
입력 크기	960 (모든 실험 공통)
평가 데이터	① 웹캠 녹화 36 장(17 초, 3 명 계속 착석) ② 1 차 룸 영상 659 장(22 분, 2 초 간격, 정답 표기) ③ 합성 엎드린 장면 40 장(4 절의 80 장 중 사람이 엎드린 장면)
정답	썸네일을 보고 2 초 단위로 표기. 0:00~3:30 사람 있음(191 장), 3:32~19:06 짐만 남음(468 장), 19:08 이후 사람 있음
측정일	2026-10-18~21

15 종을 한 프로세스에 모두 올리면 메모리 16GB 를 넘을 수 있어서, 모델마다 별도 프로세스로 실행하고 끝나면 메모리를 돌려받게 했다. 이때 MPS 가 GPU 쪽에서 쓰는 메모리는 프로세스 최대 메모리 값에 포함되지 않는다는 점을 확인했다. 예를 들어 YOLO11x 는 실제로 약 1.8GB 를 쓴다.

3. 모델 비교: 파라미터 대비 성능 (RQ1)

판정은 신뢰도가 가장 낮은 프레임에서 틀린다. 그래서 평균 대신 최저 신뢰도를 주 지표로 쓰고, 놓친 장 수를 함께 봤다. 파라미터, 연산량, COCO mAP 는 Ultralytics 공식 표(COCO val2017, 입력 640)이고, 나머지는 우리 데이터에서 잰 값이다.

표 3. 사전학습 15 종 비교 (기준 0.35, 1 차 영상은 JPEG 프레임 기준)

모델	파라미터 (M)	GFLOPs	COCO mAP50-95	녹화 36 장 사람 최저	1 차 놓침 / 오탐	1 차 사람 최저	합성 엎드림 검출	합성 최저
YOLOv8n	3.2	8.7	37.3	0.48	0 / 0	0.44	34/40	0.00
YOLOv8s	11.2	28.6	44.9	0.31	1 / 0	0.34	39/40	0.09
YOLOv8m	25.9	78.9	50.2	0.61	0 / 0	0.52	39/40	0.00
YOLOv8l	43.7	165.1	52.9	0.49	0 / 0	0.45	38/40	0.00
YOLOv8x	68.2	257.8	53.9	0.56	0 / 0	0.53	39/40	0.06
YOLO11n	2.6	6.5	39.5	0.33	1 / 0	0.00	39/40	0.34
YOLO11s	9.4	21.6	47.0	0.45	0 / 0	0.40	37/40	0.00
YOLO11m	20.1	68.1	51.5	0.58	0 / 0	0.61	39/40	0.08
YOLO11l	25.3	87.2	53.4	0.83	0 / 0	0.40	37/40	0.12
YOLO11x	56.9	195.3	54.7	0.71	0 / 0	0.47	40/40	0.38
YOLO26n	2.4	5.5	40.1	0.54	3 / 0	0.00	33/40	0.10
YOLO26s ★	9.5	20.9	47.8	0.81	0 / 0	0.47	40/40	0.36
YOLO26m	20.4	68.4	52.5	0.76	0 / 0	0.64	38/40	0.09
YOLO26l	24.8	86.8	54.4	0.88	0 / 0	0.54	39/40	0.14
YOLO26x	55.7	194.4	56.9	0.89	0 / 0	0.70	38/40	0.15

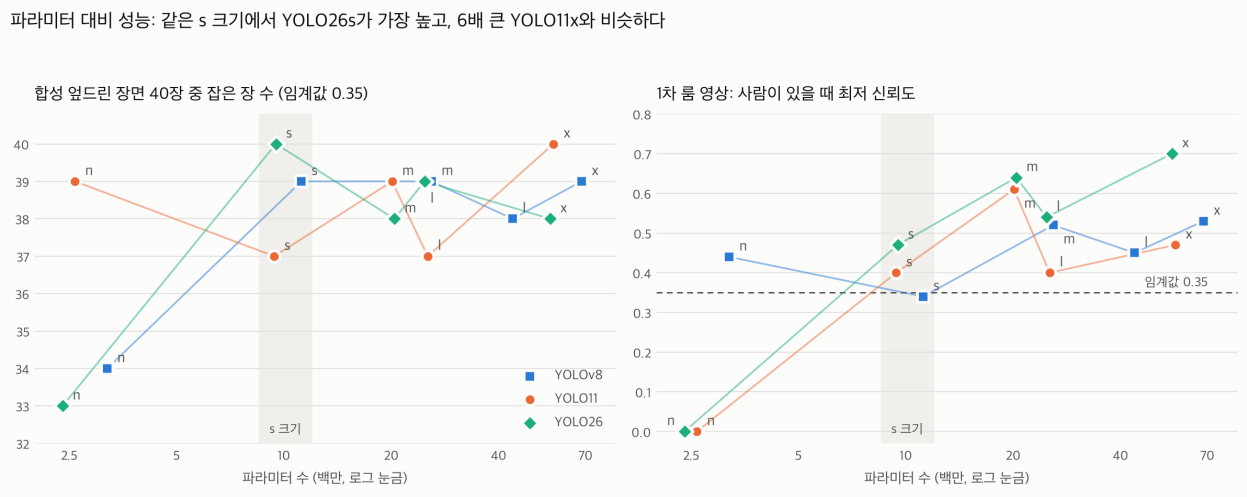


그림 1. 파라미터 수(로그 눈금)와 성능. 왼쪽은 합성 엎드린 장면 40 장 중 잡은 장 수, 오른쪽은 1 차 영상에서 사람이 있을 때의 최저 신뢰도

다섯 지표(합성 검출 수, 합성 최저, 1 차 사람 최저, 녹화 최저, COCO mAP) 모두에서, YOLO26s 보다 파라미터가 적으면서 성능이 더 높은 모델은 없었다. 15 종 중 자기보다 작으면서 더 좋은 모델이 없는 것은 26s 와 26n 뿐이고, 26n 은 가장 작은 모델이라 당연히 여기에 든다.

- **26s 대 11x:** 파라미터를 6 배 늘려도 합성 검출 수(40 대 40)와 1 차 사람 최저(0.47 대 0.47)는 같았고, 녹화 36 장 최저는 26s 가 높았다(0.81 대 0.71). 연산량은 20.9 대 195.3 GFLOPs 다.
- **n 크기:** 1 차 영상에서 사람이 있는 프레임을 놓쳤다(11n 1 장, 26n 3 장).
- **같은 s 크기:** YOLO11s 는 합성 엎드린 장면 3 장을 놓쳤고 모두 후드나 패딩 차림이었다(0.00, 0.05, 0.25). YOLOv8s 는 1 차 영상에서 1 장을 놓쳤다.

기준값은 두 오류의 피해가 다르다는 점을 고려해 0.30 으로 정했다. 원본 프레임 기준으로 빈 방의 최고 점수는 0.12 이고 합성 엎드린 장면의 최저 점수는 0.36 이어서, 0.30 은 두 값 사이에 있다. 26s 가 놓친 3:30 프레임은 사람이 나가는 순간이라 노랑이 2 초 일찍 켜질 뿐이다. 반면 엎드린 사람을 계속 놓치면 공부 중인 룸에 초록불이 켜진다. 그래서 처음 쓰던 기준값 0.35 를 0.30 으로 낮춰, 엎드린 사람 쪽 여유를 늘렸다.

같은 프레임이라도 JPEG 로 저장하면 점수가 달라지는지 확인했다. 659 장 평균 차이는 작았지만, 사람이 화면 끝으로 나가는 3:30 프레임처럼 점수가 기준값 근처인 프레임에서는 판정이 갈렸다(표 4). 그래서 기준값 근처의 판단은 영상 원본 프레임으로 확인한다.

표 4. JPEG 압축의 영향 (3:30, 사람이 화면 끝으로 나가는 프레임)

모델	원본 프레임	JPEG 프레임	659 장 평균 차이
YOLO26s	0.29	0.56	0.005
YOLO11s	0.41	0.48	0.003
YOLO11x	0.48	0.47	기록 없음

4. 테이블 검출과 감지 영역 (RQ2)

처음 계획은 테이블을 검출하고 그 박스를 넓혀 감지 영역으로 쓰는 것이었다. 그러나 COCO 의 dining table 은 대부분 옆에서 본 식탁이라, 높은 곳에서 대각선으로 내려다본 우리 테이블은 학습 분포 밖에 있었다. 녹화 36 장에서 테이블 평균 신뢰도는 0.00~0.47 에 머물렀고, 기준 0.35 를 넘긴 것은 YOLO11l 의 최고 박스(0.56)뿐이었다. 큰 모델일수록 오히려 낮아지는 경향도 보였다(11x 0.02, 26x 0.04, v8x 0.08).

표 5. 녹화 36 장 결과: 속도, 사람, 테이블

모델	MPS ms/장	CPU ms/장	사람 최저	사람 놓침 (0.35)	테이블 평균 신뢰도
YOLOv8n	33	64	0.48	0/108	0.18
YOLOv8s	48	134	0.31	6/108	0.00
YOLOv8m	103	272	0.61	0/108	0.15
YOLOv8l	184	481	0.49	0/108	0.09
YOLOv8x	231	852	0.56	0/108	0.08
YOLO11n	24	76	0.33	4/108	0.15
YOLO11s	46	154	0.45	0/108	0.10
YOLO11m	107	354	0.58	0/108	0.28
YOLO11l	125	676	0.83	0/108	0.47
YOLO11x	241	911	0.71	0/108	0.02
YOLO26n	22	94	0.54	0/108	0.19
YOLO26s ★	53	204	0.81	0/108	0.15
YOLO26m	98	363	0.76	0/108	0.14
YOLO26l	117	449	0.88	0/108	0.14
YOLO26x	220	776	0.89	0/108	0.04

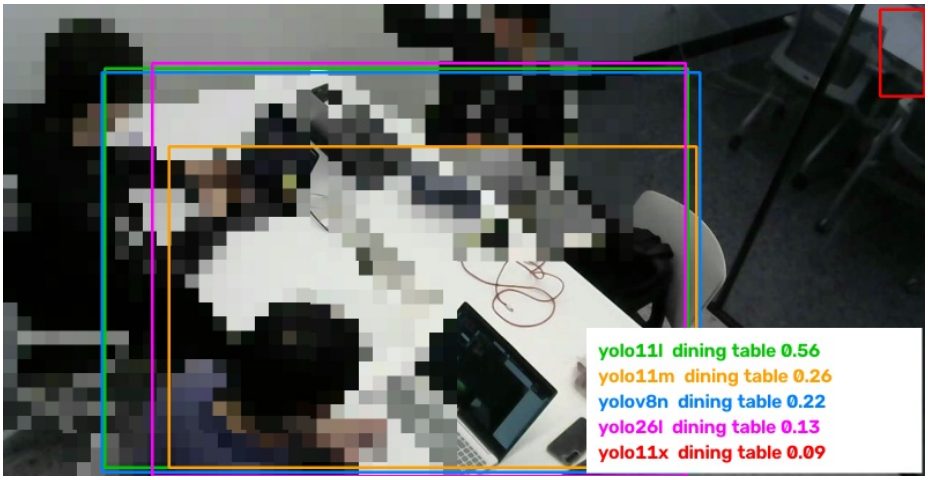


그림 2. 모델별로 가장 확실한 테이블 박스. YOLO11l(0.56)만 기준을 넘었고, YOLO11x(빨강)는 유리벽 너머 의자를 테이블로 잡았다

또 카메라가 테이블을 대각선으로 보기 때문에, 축에 맞춘 박스를 30% 넓히면 화면 거의 전체가 감지 영역이 된다. 그래서 감지 영역을 다각형으로 직접 지정하는 모듈(zone.py)을 만들었다. 사람 박스의 중심이 다각형 안에 있을 때만 재석으로 세므로, 유리벽 너머 복도를 지나가는 사람은 빠진다. 이후 팀이 파인튜닝한 v2 가 테이블을 잡게 되면서 감지 영역은 SAM 테두리 방식으로 바뀌었고, 다각형 영역은 그 전까지 판정과 검증에 쓰였다.



그림 3. 1 차 영상의 다각형 감지 영역(초록). 왼쪽은 사람이 있는 2:00, 오른쪽은 빈 방인 10:00. 사람은 모자이크했다

5. 판정 알고리즘 설계 (server.py)

판정 프로그램은 프레임 수집, 사람 검출, 감지 영역 판정, 상태 판정의 네 단계로 이뤄진다(그림 4). 같은 코드가 녹화 영상과 실시간 스트림을 모두 처리하도록, 영상 파일은 영상 속 시각으로, 스트림은 실제 시각으로 시간을 잰다.

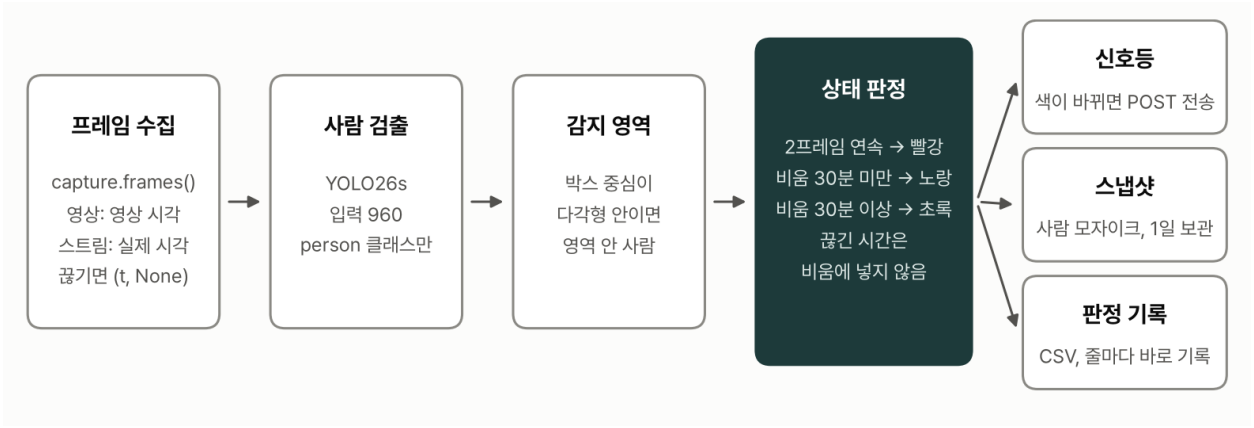


그림 4. server.py 의 판정 흐름

표 6. 상태 정의

상태	조건	신호등
사용중	감지 영역 안 사람 신뢰도가 기준 이상인 프레임이 2 번 연속	빨강
비움 30 분 미만	마지막으로 사람을 확인한 뒤 비운 시간이 30 분 미만	노랑
비움 30 분 이상	비운 시간이 30 분 이상(끊긴 시간 제외)	초록

규칙을 정할 때는 오류마다 피해가 다르다는 점을 먼저 따졌다. 가장 피해가 큰 오류는 주인이 있는데 초록이 켜져 다른 학생이 짐을 치우는 경우다. 표 7 에는 결정마다 막으려는 오류를 함께 적었다.

표 7. 설계 결정과 근거

결정	막으려는 오류	근거
2 프레임 연속 확인	순간 오검출 하나가 30 분 타이머를 초기화해 알박기를 계속 가림	타이머는 사람이 한 번만 잡혀도 처음부터 다시 셈
끊긴 시간을 비움에서 제외	스트림 끊김을 사람 없음으로 세어 공부 중인 룸에 초록	끊김은 정보가 없는 상태이지 부재가 아님
박스 중심으로 영역 판정	유리벽 너머 복도 사람을 재석으로 셈	영역에 일부만 걸친 박스 제외
상태가 바뀐 순간만 스냅샷, 사람 모자이크, 1 일 보관	영상 상시 저장에 따른 개인정보 위험	다툼이 생겼을 때 판정 근거만 확인
판정 기록을 한 줄씩 바로 저장	강제 종료 때 기록 유실	버퍼에 남은 기록이 사라지는 문제를 시험에서 발견
신호등은 색이 바뀔 때만 전송	불필요한 통신	HTTP POST {"color": "red" | "yellow" | "green"}

6. 판정 검증 (RQ3)

정답을 표기한 1 차 영상으로 판정 결과를 프레임 단위로 비교했다. 이 영상의 앞 80%는 이후 v2 학습에 쓰였기 때문에, v2 는 학습에 쓰지 않은 뒤쪽 20%(17:34 이후 132 장)로만 평가했다.
사전학습 모델은 이 영상으로 학습하지 않았으므로 659 장 전체로 평가했다.

표 8. server.py 검증 시험

시험	설정	결과
타이머 동작	1 프레임 확인, 초록 기준 10 분	빨강 191, 노랑 299, 초록 169. 정답과 불일치 0 장. 마지막 검출(3:30) 10 분 뒤인 13:30 에 초록
YOLO11x	기준 0.35, 2 프레임 확인, 30 분	빨강 189, 노랑 470. 불일치 2 장(0:00, 19:08 입장 첫 프레임)
사전학습 YOLO26s	기준 0.30, 2 프레임 확인, 30 분, 659 장	656 장 일치(99.5%). 불일치 3 장(입장 첫 프레임 2 장, 3:30 신뢰도 0.29)
파인튜닝 v2	기준 0.35, 학습 외 구간 132 장	131 장 일치. 불일치 1 장(19:08 입장 첫 프레임). 사람 최저 0.79, 빈 룸 최고 0.00
스트림 끊김	임시 스트림 서버, 초록 기준 0.5 분, 10 초에 끊고 31 초 뒤 재연결	끊긴 시간을 빼고 1:03 에 초록. 신호등 수신기가 yellow, green 순서로 받음
모자이크	상태가 바뀐 순간의 스냅샷	화면 속 3 명 모두 모자이크
강제 종료	실행 중 프로세스 종료	그때까지의 판정 기록이 CSV 에 남음

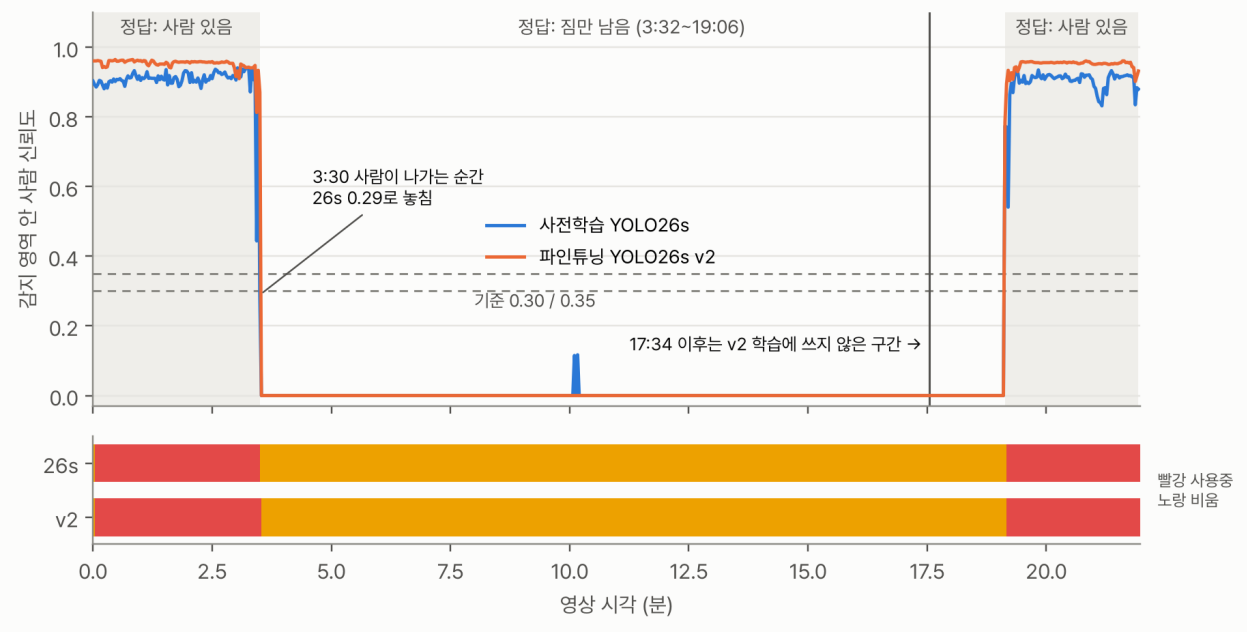


그림 5. 1 차 영상의 감지 영역 안 사람 신뢰도(위)와 판정된 신호등 색(아래). 회색은 정답상 사람이 있는 구간

불일치는 두 종류로 나뉜다. 첫째는 입장 순간의 2 초 지연이다. 2 프레임 연속 확인 규칙이 의도한 동작이며, 순간 오검출을 막는 대가로 받아들였다. 둘째는 3:30 의 검출 실패로, 사람이 화면 끝으로 나가며 몸이 잘린 프레임이다. 노랑이 2 초 일찍 켜질 뿐 초록과는 무관하다. 잘못된 초록은 어떤 시험에서도 나오지 않았다.

점수가 기준값에서 얼마나 떨어져 있는지도 비교했다. 사람이 있을 때의 최저 신뢰도는 사전학습 26s 가 0.29 로 기준 0.30 아래까지 내려갔지만, v2 는 학습 외 구간에서도 0.79 로 기준 0.35 보다 0.44 높았다. 빈 룸의 최고 점수도 26s 는 0.12(10 분 무렵 한 번)였고 v2 는 0.00 이었다. 파인튜닝 뒤에는 사람이 있을 때와 빈 룸일 때 모두 기준값과의 간격이 넓어졌다.

7. 추론 위치 비교 실험 설계

라즈베리파이 안에서 추론하는 방식과 서버에서 추론하는 방식을 공정하게 비교하도록 실험을 설계했다. 바꾸는 변인은 연산 장치 하나이고, 모델, 입력 크기, 기준값, 감지 영역, 판정 규칙, 판정 코드는 고정했다. 같은 영상을 양쪽에서 같은 명령으로 돌리면 장치 차이만 남는다.

표 9. 비교 지표와 제안 기준

지표	재는 법	제안 기준
판정 일치율	정답 구간과 신호등 색이 같은 프레임 비율	99% 이상
1 장 처리 시간	판정 기록의 프레임별 시간(평균, 최대)	30 초 이하
빨강 반응 시간	사람이 들어온 시각부터 첫 빨강까지	1 분 이하
최대 메모리	실행 중 메모리 최댓값	기기 RAM 의 70% 이하
끊김 시 동작	실행 중 Wi-Fi 를 1 분 끊고 신호등 기록	초록이 잘못 켜지지 않음

제안 기준의 처리 시간 30 초는 빨강 반응 1 분에 맞춘 값이다. 이후 팀은 판정 간격을 1 초로 정했고, 라즈베리파이 실측(1 장 2,832ms)이 이를 충족하지 못해 서버 방식을 택했다.

8. 생성형 데이터 실험 (RQ4)

엎드린 사람 데이터가 부족해서, 생성형 데이터로 채울 수 있는지 시험했다. Stable Diffusion v1.5 인페인팅으로 1 차 영상의 빈 방 프레임(8:00)에 엎드린 사람을 그려 넣었다. 자리 4 곳 중 A, B, C 는 실제로 사람이 앉았던 자리이고, D 는 아무도 앉지 않아 직접 정했다. 자리 주변 512×512 만 잘라 그린 뒤 마스크 안쪽만 원본에 다시 붙였기 때문에, 그린 자리 밖은 실제 화면 그대로다.

사람이 그려졌는지는 CLIP(ViT-B/32)으로 먼저 걸렀다. YOLO 와 다른 모델로 거르기 때문에, YOLO 가 놓치는 이미지도 버려지지 않는다. 시험 생성 16 장에서 기준 0.9 가 사람의 눈 판정과 16 장 모두 일치했다. 최종 판정은 사람이 눈으로 했고, 1 장을 만드는 데 약 70 초가 걸렸다.

표 10. 생성 회차별 결과 (엎드림 검출은 기준 0.35)

회차	바꾼 것	생성	사람 있음	엎드림	엎드림 검출 **11x · 26l · 26s**
시험	공통 지시문, 옷차림 4 가지	16	5	3	3 · 3 · 3
2 차	자리별 방향, 부정 지시문, 남녀 × 옷차림	32	24	16	16 · 16 · 16
어려운 장면	외투·후드·담요로 머리와 몸을 가림, D 마스크를 책상 쪽으로 이동	32	30	21	21 · 20 · 21
합계		80	59	40	40 · 39 · 40

- **지시문 효과:** 자리별 방향을 지시문에 넣자, 뒷모습이 보이는 C 자리에 사람이 그려진 비율이 0/4 에서 8/8 로 올랐다.
- **마스크 위치:** D 자리는 2 차에서도 1/8 이었지만, 마스크를 책상 가장자리 쪽으로 옮기자 7/8 이 됐다. 사람이 놓일 책상 면이 마스크 안에 있어야 사람을 그린다.

- **CLIP 거르기:** 2 차에서 엎드린 16 장을 모두 남기고 사람 없는 8 장을 모두 버렸다. 깨어 있는 자세 4 장과 깨진 이미지 3 장은 거르지 못해, 사람의 검수가 필요했다.
- **약점 발견:** 후드를 쓰고 흰 베개에 엎드린 장면(A_5)을 YOLO26l 은 0.14 로 놓쳤고, YOLO11x 는 0.38 로 겨우 잡았다. YOLO26s 는 0.42 로 잡았다.
- **오탐 확인:** 의자에 외투만 걸린 장면(A_2)은 어떤 모델도 사람으로 잡지 않았다.



그림 6. 어려운 장면 32 장. 사람은 모두 Stable Diffusion 이 그린 가상 인물이다. 노란 숫자는 CLIP 점수와 YOLO11x, 26l 신뢰도

합성 데이터는 학습에 쓰지 않았다. 이유는 두 가지다. 첫째, 80 장 중 YOLO 가 놓친 엎드린 장면은 1 장뿐이라, 학습에 쓸 어려운 표본 1 장을 얻는 데 약 93 분(80 장 × 70 초)이 들었다. 둘째, 실제 약점인 천장 각도의 테이블은 합성 사진으로 풀 수 없었다. 대신 합성 사진은 약점을 찾는 도구로 쓸모가 있었고, 그 결과 후드를 쓰고 엎드린 장면을 시범 수집에서 먼저 모으기로 했다. 합성 사진의 검출률은 실제 재현율이 아니므로, 모델 선택과 기준값은 실제 영상으로 정했다.

9. 공개 데이터셋 조사 (RQ5)

우리 영상과 비슷한 공개 데이터가 있으면 평가를 보강할 수 있어서, 공식 페이지, 논문, 저장소, 라이선스 문서를 직접 확인해 10 종을 조사했다. 데이터 파일은 내려받지 않았다.

표 11. 공개 데이터셋 비교 (기준: 방 모서리 높은 곳에서 테이블 1 개와 의자 4 개를 내려다보는 카메라)

데이터셋	장면과 카메라 각도	규모	라이선스	적합도
Edinburgh Office Monitoring	대학 사무실 4 곳, 방 위쪽 고정 카메라	20 일, 456,714 장	CC BY-NC-SA 3.0	높음
Employee Sleeping (Roboflow)	사무실 책상에 엎드린 사람, CCTV 각도	3,042 장	CC BY 4.0 표기, 출처 불명	중간
SCB-Dataset (3-U)	교실, 정면·측면·후면	13,330 장, 3-U 671 장	비상업 학술용	중간
CAVIAR	연구소 로비, 가방 두고 가기, 거의 바로 위	28 클립	CC BY-SA	중간
PIROPO	실내 방 2 곳, 벽·천장 카메라	10 만 장 이상	연구 목적 무료	중간
Toyota Smarthome	아파트 일상, 방 모서리 위쪽	16,115 클립	비상업, 재배포 금지	중간
CEPDOF	작은 강의실, 천장 어안	25,504 장	비상업 또는 ODbL	낮음
EduNet	인도 교실, 여러 각도	7,851 클립	표기 없음	낮음
Classroom Behavior	교실 학생, 각도 섞임	4,881 장	CC BY 4.0 표기, 출처 불명	낮음
ABODA	물건이 버려진 장면	영상 11 개	표기 없음	낮음

가장 가까운 것은 Edinburgh Office Monitoring 이다. 사무실 위쪽 고정 카메라로 20 일을 1 초 1 장 간격으로 찍었고, 빈 방과 앉은 사람에 프레임별 라벨이 있어 빈 방 오검출을 함께 볼 수 있다. 엎드린 사람은 Employee Sleeping 과 SCB-Dataset 의 leaning over the table 라벨이 가깝지만, 전자는 이미지 출처 설명이 없고 후자는 허락 없는 배포를 금지한다. 스터디룸 같은 작은 방에서 책상에 엎드린 사람을 방 모서리 각도로 찍은 공개 데이터는 찾지 못했다. 그래서 평가와 학습에는 우리 룸에서 직접 모은 데이터가 필요하다고 판단했다.

10. 실시간 수신 구조 (RQ6)

라즈베리파이가 RTSP 로 보내는 카메라 영상을 노트북에서 받아 실시간으로 사람을 표시하는 프로그램(realtime/live.py)을 만들었다. 이 프로그램은 수신과 추론을 나눠서 돌린다. 수신 스레드는 프레임을 계속 받아 가장 최근 1 장만 들고 있고, 추론 쪽은 그 1 장만 가져간다. 그래서 추론이 수신보다 느려도 지연이 쌓이지 않는다. RTSP 는 TCP 로 받는다. UDP 로 받으면 Wi-Fi 에서 패킷이 빠져 깨진 프레임이 들어오기 때문이다. 수신이 실패하면 2 초 뒤 다시 연결한다. 이 구조로 1280×720·15fps 영상에 YOLO26s 를 돌려 초당 17.8 장을 표시했다.

11. 재현성과 개인정보 보호

다른 팀원이 같은 결과를 다시 낼 수 있도록 코드, 프레임별 결과, 실험 기록을 GitHub 에 올렸다.

표 12. 박서준이 올린 파일 (지금은 통합 코드모음의 01_판정코드, 02_데이터·실험에 있음)

파일	역할
server.py	판정 본체(상태 판정, 신호등 전송, 스냅샷, 판정 기록)
capture.py	영상·스트림 프레임 수집, 끊김 감지와 재연결
zone.py	다각형 감지 영역 지정과 영역 판정 함수
compare.py	15 종을 모델마다 별도 프로세스로 돌리는 비교 실험
realtime/live.py	RTSP 실시간 인식 화면
synthetic/	합성 데이터 생성·거르기 코드, 자리 좌표, 15 종 평가 결과
1 차_영상_결과.csv	15 종 × 659 장 프레임별 결과(9,885 행)
EXPERIMENTS.md	모든 실험의 설정, 수치, 해석
DATASETS.md	공개 데이터셋 10 종 조사
image/	실험 이미지 9 장과 설명

저장소가 공개이므로 개인정보 보호를 처음부터 작업 규칙에 넣었다. 실제 사람이 나오는 이미지는 YOLO11x 로 사람을 찾고 박스를 사방 25% 넓힌 뒤 24 픽셀 단위로 모자이크했다. 팀원 얼굴이 나오는 영상, 스냅샷, 모델 가중치는 저장소에 올라가지 않도록 업로드 제외 목록(.gitignore)으로 막았다.

12. 팀 학습 데이터와 성능 지표 다시 분석

최종 모델 v2 의 학습 데이터와 학습·평가 기록은 황예성이 만들었다. 발표 뒤 그 라벨 파일 727 개와 기록을 다시 세어, 데이터 구성과 지표의 범위를 정리했다.

표 13. 학습 데이터 구성 (727 장)

출처	학습	검증	사람이 있는 장	비고
1 차 영상 (천장 고정 카메라, 앞 17.6 분, 2 초 간격)	475	53	105 장 (20%)	테이블은 고정된 정답 박스 하나
휴대폰 영상 (테이블 주변)	144	37	39 장 (22%)	테이블 정답 181 장을 모두 눈으로 검수
엎드린 사람 사진	18	0	18 장	사진 6 장을 3 번씩 복사
합계	637	90	162 장 (22%)	

표 14. 클래스별 박스 수와 크기

클래스	박스 수	화면 대비 면적 (중앙값)	비고
노트북	1,833	4.0%	
테이블	824	57.4%	
마우스	653	0.14%	아주 작은 물체
사람	405	10.6%	엎드린 사람은 사진 6 장이 전부
책	354	1.5%	
휴대폰	223	0.29%	아주 작은 물체
가방	121	2.5%	101 개가 휴대폰 영상, 천장 영상에는 20 개
키보드	53	0.7%	
컵	23	0.18%	아주 작은 물체
핸드백	16	5.7%	모두 휴대폰 영상

데이터에서 보이는 점은 네 가지다.

- **사람 데이터:** 사람이 있는 장은 22%이고, 엎드린 사람은 사진 6 장(2 명)이 전부다.
- **천장 각도의 가방:** 천장 영상의 가방은 20 개뿐이다. 파인튜닝한 YOLO26s v2 가 웹캠 영상에서 가방을 0% 잡은 원인 중 하나로 보인다. 다만 같은 데이터로 학습한 YOLO26m v2 는 100%를 잡았으므로 데이터만의 문제는 아니다.
- **자동 라벨:** 사람·물건 라벨은 yolov10s 가 만든 것(기준 0.35, 엎드린 사진은 0.2)이고, 눈으로 검수한 것은 테이블뿐이다.
- **작은 물체:** 마우스, 휴대폰, 컵은 화면의 0.3%보다 작다.

표 15. 파인튜닝 전후 성능 지표

평가	데이터	지표	파인튜닝 전 YOLO26s	파인튜닝 v2
학습 중 검증	검증 90 장, 10 개 클래스	precision / recall / mAP50 / mAP50-95	-	0.768 / 0.741 / 0.813 / 0.749
테이블	1 차 영상 뒤 20% 131 장	정답 박스와 IoU 0.5 이상	2/131 (2%)	131/131 (100%), 평균 IoU 0.976
테이블	웹캠 영상 36 장	정답 박스와 IoU 0.5 이상	0%	100%, 평균 IoU 0.955
엎드린 사람	1 차 영상 마지막 84 프레임 (7 초)	신뢰도 0.35 이상	78/84 (92.9%)	84/84 (100%)
사람·물건	웹캠 영상 36 장	정답 개수 대비 검출 비율	사람 100%, 가방 100%	사람 100%, 가방 0%
신호등 판정	1 차 영상 659 장 (v2 는 학습에 안 쓴 132 장)	정답 색과 같은 장 수	656/659 (99.5%)	131/132

지표를 읽을 때 주의할 점은 다섯 가지다.

- **검증 점수:** 검증 90 장은 학습 프레임 사이에서 뽑았다. 1 차 영상의 검증 프레임은 가장 가까운 학습 프레임과 2 초밖에 떨어져 있지 않아서, 같은 장면을 다시 본 점수에 가깝다.
- **평가한 체크포인트:** 평가에는 mAP50-95 가 가장 높았던 17 에포크 모델(best.pt)을 썼다. 마지막 25 에포크에서는 precision 이 0.586 까지 떨어졌다.
- **테이블 100%의 범위:** 카메라가 고정이라 모든 프레임에 같은 정답 박스를 썼고, 학습에도 같은 박스를 썼다. 그래서 이 100%는 이 카메라 위치에서 맞힌 값이다.
- **엎드린 사람 100%의 범위:** 84 프레임은 1 명이 7 초 동안 엎드린 한 장면이다.
- **클래스별 검증 결과:** 혼동 행렬에서 사람과 테이블은 거의 다 맞혔다. 휴대폰과 마우스는 서로 헷갈린 경우가 있었고, 가방 일부는 핸드백으로 잡혔다.

13. 그 밖의 기여

- **회의 보고서:** 1 차·2 차 회의 보고서를 팀원과 함께 작성했다.
- **발표 자료:** 실험 결과를 반영한 PPT 수정본(18 장)을 만들고, 검증 결과 슬라이드와 부록 2 장을 추가했다.

- **예상 질의응답:** 결과물 전체를 평가자 관점에서 검토해 팀 Q&A 문서에 예상 질문 15 개(Q17~Q31)와 답변을 더했다.
- **학습·평가 데이터 분리 점검:** 판정 검증 영상의 앞 80%가 v2 학습에 쓰였다는 점을 확인하고, v2 성능을 학습 외 구간으로 다시 계산했다.

14. 결론

이번 작업으로 기여한 것은 네 가지다.

- **모델 선택:** 파라미터 대비 성능 분석으로, 합성 엎드린 장면 검출 수와 1 차 영상 사람 최저 신뢰도가 YOLO11x 와 같으면서 파라미터는 6 분의 1, 연산량은 9 분의 1 인 YOLO26s 를 골랐다.
- **오류 비용 반영:** 오류마다 피해가 다르다는 점을 판정 규칙과 평가 지표에 반영했다. 잘못된 초록에 대비해 끊긴 시간을 비운 시간에서 빼고 모델은 최저 신뢰도로 비교했으며, 알박기가 가려지는 오류는 2 프레임 연속 확인으로 막았다.
- **검증 방법:** 정답 영상과 프레임 단위로 비교하고, 학습에 쓴 구간을 분리해 평가했다. 어떤 시험에서도 잘못된 초록은 나오지 않았다.
- **생성형 데이터의 쓰임:** 합성 사진을 학습 데이터가 아니라 약점을 찾는 도구로 써서, 현장 수집에서 먼저 모을 장면을 정했다.